

第十一週 碩士班一年級

深度強化學習

Grid World 、策略梯度推導與 Actor-Critic

價值估計與策略最佳化

本週的學習目標

以同一個小型環境比較規劃方法，再推導如何直接最佳化策略。

教學段落	學習成果	頁次
MDP 與動態規劃	手算 Grid World 的價值迭代與策略迭代	03–12
價值學習	區分 MC 、 TD 、 SARSA 與 DQN 的 target	13–15
Policy Gradient	從軌跡機率推導至 Reward-to-Go 與 Baseline	16–26
Actor–Critic 與 PPO	解釋 Actor 、 Critic 、 GAE 與 clipping	27–40

MDP：決策與環境回饋

先觀察目前狀態並選動作，再收到 reward 與下一狀態。

$$a_t \sim \pi(\cdot \mid s_t), \quad s_{t+1} \sim P(\cdot \mid s_t, a_t)$$

$$r_{t+1} = R(s_t, a_t, s_{t+1})$$

Markov 假設：給定目前狀態與動作，未來轉移不再依賴更早歷史。

Model-free 仍然需要環境給 reward，只是不要求先知道轉移模型。

Trajectory 與折扣回報

一條 trajectory 是一次互動結果；每個時間點都有自己的未來回報。

$$\tau = (s_0, a_0, r_1, s_1, \dots, a_{T-1}, r_T, s_T)$$

$$G_t = \sum_{k=0}^{T-t-1} \gamma^k r_{t+k+1}, \quad G_t = r_{t+1} + \gamma G_{t+1}$$

$$0 \leq \gamma \leq 1, \quad G_T = 0$$

有限回合在適當條件下可不折扣；持續任務通常使用折扣控制遠期回報。

V、Q 與 Advantage

價值必須指明後續依循的策略；同一狀態在不同策略下可有不同價值。

$$V^{\pi}(s) = \mathbb{E}_{\pi}[G_t \mid s_t = s]$$

$$Q^{\pi}(s, a) = \mathbb{E}_{\pi}[G_t \mid s_t = s, a_t = a]$$

$$V^{\pi}(s) = \sum_a \pi(a \mid s) Q^{\pi}(s, a), \quad A^{\pi}(s, a) = Q^{\pi}(s, a) - V^{\pi}(s)$$

V 評估依策略選動作的平均表現；Q 評估先指定某個動作的表現。

Bellman 方程：評估與最優控制

長期價值可以拆成一步 reward 與下一狀態的價值。

$$V^{\pi}(s) = \sum_a \pi(a | s) \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma V^{\pi}(s')]$$

$$V^*(s) = \max_a \sum_{s'} P(s' | s, a) [R(s, a, s') + \gamma V^*(s')]$$

期望方程評估指定策略。最適方程對可選動作取最大值。

經典動態規劃假設轉移模型與 reward 已知。

共用 Grid World：環境設定

兩種迭代都使用同一個 2×2 網格。每一步花費一分，目標是儘早抵達 G。



$$\mathcal{A} = \{\uparrow, \downarrow, \leftarrow, \rightarrow\}, \quad \gamma = 0.9$$

$$r_{t+1} = -1 \text{ (including entry to G)}, \quad V(G) = 0$$

移動確定，撞牆留在原格並照樣扣分；進入 G 後回合結束。

價值迭代：第一次 Bellman backup

從零值表開始，同步更新所有非終止狀態。

$$V_0(s) = 0, \quad V_{k+1}(s) = \max_a \{-1 + 0.9V_k(f(s, a))\}$$

$$V_1(A) = V_1(B) = V_1(C) = -1$$

$$V_2(A) = \max \underbrace{\{-1 + 0.9(-1)\}}_{\rightarrow, \downarrow, \uparrow, \leftarrow} = -1.9$$

第一輪只看見立即成本。第二輪開始把「還要再走一步」的成本傳回 A。

價值迭代：收斂與策略抽取

第二輪已得到最優值表；再做一次 backup 可確認不再改變。

迭代	A	B	C	G
初始	0	0	0	0
第一輪	-1	-1	-1	0
第二輪	-1.9	-1	-1	0
第三輪	-1.9	-1	-1	0

$$V_2(B) = \max\{-1, -1.9\} = -1, \quad V_2(C) = -1$$

$$\pi^*(A) \in \{\rightarrow, \downarrow\}, \quad \pi^*(B) = \downarrow, \quad \pi^*(C) = \rightarrow$$

策略迭代：先評估一個會繞圈的策略

初始策略讓 A、B 互相來回，C 也先走向 A。固定策略後解聯立方程。



$$V^{\pi_0}(A) = -1 + 0.9V^{\pi_0}(B), \quad V^{\pi_0}(B) = -1 + 0.9V^{\pi_0}(A)$$

$$V^{\pi_0}(C) = -1 + 0.9V^{\pi_0}(A)$$

$$V^{\pi_0}(A) = V^{\pi_0}(B) = V^{\pi_0}(C) = \frac{-1}{1 - 0.9} = -10$$

策略迭代：改善、重評估與停止

用舊策略的值表比較每個動作，改善後再重新評估整個策略。

$$Q^{\pi_0}(B, \downarrow) = -1 + 0.9(0) = -1 > -10$$

$$Q^{\pi_0}(C, \rightarrow) = -1, \quad \pi_1 = (A:\rightarrow, B:\downarrow, C:\rightarrow)$$

$$V^{\pi_1}(B) = V^{\pi_1}(C) = -1, \quad V^{\pi_1}(A) = -1 + 0.9(-1) = -1.9$$

A 在首次改善時各動作同分，保留向右。再次改善後策略不變，因此停止。

兩種迭代的差別

差別在評估與改善如何交替，不在於最後要解決的目標。

面向	價值迭代	策略迭代
主要維護	目前的值表	目前的策略與其值表
每輪操作	對每個動作做 backup，再取最大值	固定策略評估，完成後再改善
本例的起點	全部價值設為零	一個會繞圈的確定性策略
停止依據	值表變化或 Bellman residual 足夠小	改善後策略不再改變
相同結果	最短路徑的最優價值	最短路徑的最優價值

Model-free 價值估計：MC 與 TD

不知道轉移機率時，改用環境樣本建立學習 target。

$$\text{MC: } y_t = G_t$$

$$\text{TD}(0): y_t = r_{t+1} + \gamma(1 - d_t)V(s_{t+1})$$

$$V(s_t) \leftarrow V(s_t) + \alpha[y_t - V(s_t)]$$

MC 使用完整實際回報；TD 借用下一狀態的預測，因此可提早更新。

真正終止時不 bootstrap；單純的時間截斷需另行判斷。

SARSA 與 Q-learning 的 target

兩者都用 TD 更新 Q ；關鍵差異是下一個動作如何決定。

$$y_{\text{SARSA}} = r + \gamma Q(s', a'), \quad a' \sim \pi_{\text{behavior}}(\cdot \mid s')$$

$$y_Q = r + \gamma \max_{a'} Q(s', a')$$

$$Q = 0.8, \alpha = 0.1, r = 0, \gamma = 1 : \quad \begin{cases} 0.8 + 0.1(0.9 - 0.8) = 0.81 & \text{SARSA} \\ 0.8 + 0.1(1.0 - 0.8) = 0.82 & \text{Q-learning} \end{cases}$$

本例實際下一動作的 Q 為零點九，而最大 Q 為一，所以下一步 target 不同。

DQN：函數逼近與穩定化

神經網路取代 Q table，仍然使用 Bellman target 學習。

$$y = r + \gamma(1 - d) \max_{a'} Q_{\phi-}(s', a')$$

$$L_Q(\phi) = \mathbb{E}_{(s,a,r,s',d) \sim \mathcal{D}} [(Q_{\phi}(s, a) - \text{sg}(y))^2]$$

Replay Buffer 重複利用資料。Target Network 延後同步 target 參數。

Double DQN 處理高估，PER 改善採樣，Dueling 分解表示，DRQN 引入記憶。

Policy-Based：參數化動作分布

Actor 直接輸出機率分布，適用離散或連續動作。

$$\pi_{\theta}(a \mid s) = \frac{\exp z_{\theta,a}(s)}{\sum_b \exp z_{\theta,b}(s)} \quad (\text{discrete})$$

$$a \sim \mathcal{N}(\mu_{\theta}(s), \Sigma_{\theta}(s)) \quad (\text{continuous})$$

先用策略採樣，再以回報判斷哪些行為應更常出現。

連續情況的策略值是機率密度，動作範圍與探索強度需另行設計。

推導一：目標函數與假設

先明確定義有限時域的折扣目標，後續每一步都沿用同一套記號。

$$J(\theta) = \mathbb{E}_{\tau \sim p_\theta}[G_0(\tau)], \quad G_0(\tau) = \sum_{t=0}^{T-1} \gamma^t r_{t+1}$$

$$\theta_{k+1} = \theta_k + \alpha \nabla_\theta J(\theta_k)$$

環境轉移、初始狀態分布與 reward 不直接依賴策略參數。

策略可微，支撐適當，且允許交換微分與求和或積分。

推導二：一條軌跡的機率

軌跡機率由初始狀態、每一步策略機率與環境轉移機率相乘得到。

$$p_{\theta}(\tau) = \rho_0(s_0) \prod_{t=0}^{T-1} \pi_{\theta}(a_t \mid s_t) P(s_{t+1} \mid s_t, a_t)$$

$$J(\theta) = \sum_{\tau} p_{\theta}(\tau) G_0(\tau)$$

策略影響整條軌跡的出現機率，因此也影響期望回報。

此處 reward 由轉移決定；若 reward 隨機，可納入環境條件分布。

推導三：交換微分與期望

將微分移入軌跡求和，再利用 log-derivative identity 。

$$\nabla_{\theta} J = \sum_{\tau} G_0(\tau) \nabla_{\theta} p_{\theta}(\tau)$$

$$\nabla_{\theta} \log p_{\theta}(\tau) = \frac{\nabla_{\theta} p_{\theta}(\tau)}{p_{\theta}(\tau)}$$

$$\nabla_{\theta} J = \sum_{\tau} p_{\theta}(\tau) G_0(\tau) \nabla_{\theta} \log p_{\theta}(\tau) = \mathbb{E}_{\tau}[G_0 \nabla_{\theta} \log p_{\theta}(\tau)]$$

推導四：環境項的梯度消失

乘積取 $\log$ 後成為總和；只有策略項含有需要最佳化的參數。

$$\log p_{\theta}(\tau) = \log \rho_0(s_0) + \sum_{t=0}^{T-1} [\log \pi_{\theta}(a_t \mid s_t) + \log P(s_{t+1} \mid s_t, a_t)]$$

$$\nabla_{\theta} \log p_{\theta}(\tau) = \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t \mid s_t)$$

這就是不必對環境模型反傳梯度，仍能估計策略梯度的原因。

推導五：REINFORCE 估計式

把軌跡的 log-gradient 代回目標梯度，再以多條軌跡取樣平均。

$$\nabla_{\theta} J = \mathbb{E}_{\tau} \left[G_0 \sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t \mid s_t) \right]$$

$$\hat{g} = \frac{1}{N} \sum_{i=1}^N \sum_{t=0}^{T-1} G_0^{(i)} \nabla_{\theta} \log \pi_{\theta}(a_t^{(i)} \mid s_t^{(i)})$$

同一條軌跡的每一步，都先使用同一個完整回報加權。

低於其他樣本的正回報，仍可能提供正權重；Baseline 才建立相對好壞的比較。

推導六：過去 reward 的梯度期望為零

給定動作之前的歷史，過去 reward 已經確定，無法由現在動作改變。

$$\mathbb{E}[\nabla_{\theta} \log \pi_{\theta}(a_t \mid s_t) \mid h_t] = \sum_a \pi_{\theta}(a \mid s_t) \nabla_{\theta} \log \pi_{\theta}(a \mid s_t) = \nabla_{\theta} 1 = 0$$

$$B_t = \sum_{u=0}^{t-1} \gamma^u r_{u+1}$$

$$\mathbb{E}[B_t \nabla_{\theta} \log \pi_{\theta}(a_t \mid s_t)] = \mathbb{E}[B_t \mathbb{E}[\nabla_{\theta} \log \pi_{\theta}(a_t \mid s_t) \mid h_t]] = 0$$

推導七： Reward-to-Go 與折扣因子

刪去過去 reward，保留當下動作之後的回報，再分解出外層折扣。

$$\nabla_{\theta} J = \mathbb{E} \left[\sum_{t=0}^{T-1} \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \sum_{u=t}^{T-1} \gamma^u r_{u+1} \right]$$

$$\sum_{u=t}^{T-1} \gamma^u r_{u+1} = \gamma^t \underbrace{\sum_{k=0}^{T-t-1} \gamma^k r_{t+k+1}}_{G_t}$$

$$\boxed{\nabla_{\theta} J = \mathbb{E} \left[\sum_{t=0}^{T-1} \gamma^t G_t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) \right]}$$

推導八： Policy Gradient Theorem

對每個狀態與動作取條件期望，可將抽樣回報換成 Q 函數。

$$\mathbb{E}[G_t \mid s_t = s, a_t = a] = Q^{\pi_\theta}(s, a)$$

$$\nabla_\theta J = \mathbb{E} \left[\sum_{t=0}^{T-1} \gamma^t Q^{\pi_\theta}(s_t, a_t) \nabla_\theta \log \pi_\theta(a_t \mid s_t) \right]$$

$$\eta_\theta(s) = \sum_{t=0}^{T-1} \gamma^t \Pr_\theta(s_t = s), \quad \boxed{\nabla_\theta J = \sum_s \eta_\theta(s) \sum_a \nabla_\theta \pi_\theta(a \mid s) Q^{\pi_\theta}(s, a)}$$

推導九：Baseline 與 Actor loss

對當前動作不變的狀態 baseline，其 score-weighted 期望為零。

$$\sum_a \pi_\theta(a | s) b(s) \nabla_\theta \log \pi_\theta(a | s) = b(s) \nabla_\theta \sum_a \pi_\theta(a | s) = 0$$

$$\hat{A}_t = G_t - V_\phi(s_t), \quad \nabla_\theta J = \mathbb{E} \left[\sum_t \gamma^t (G_t - b(s_t)) \nabla_\theta \log \pi_\theta(a_t | s_t) \right]$$

$$L_{\text{actor}}(\theta) = -\frac{1}{N} \sum_{i,t} \gamma^t \log \pi_\theta(a_t^{(i)} | s_t^{(i)}) \text{sg}(\hat{A}_t^{(i)})$$

Critic 、 Advantage 與收斂的判斷

Critic 學目前策略的期望回報；預測準確並不保證策略表現好。

$$\arg \min_v \mathbb{E}[(G_t - v)^2 \mid s_t = s] = \mathbb{E}[G_t \mid s_t = s] = V^\pi(s)$$

$$G_t = 120, \quad V_\phi(s_t) = 100 \quad \implies \quad \hat{A}_t = 20$$

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s), \quad \sum_a \pi(a \mid s) A^\pi(s, a) = 0$$

平均 Advantage 為零對任意策略都成立；測試回報與任務成功率才反映行為品質。

Actor 與 Critic：同一批資料的不同目標

先採樣並固定 target 與 Advantage，再更新兩個網路。

$$L_{\text{actor}} = -\mathbb{E}_{\text{batch}}[\log \pi_{\theta}(a_t \mid s_t) \text{sg}(\hat{A}_t)]$$

$$L_V(\phi) = \frac{1}{2} \mathbb{E}_{\text{batch}}[(V_{\phi}(s_t) - \text{sg}(y_t))^2]$$

$$\theta \leftarrow \theta - \alpha \nabla_{\theta} L_{\text{actor}}, \quad \phi \leftarrow \phi - \beta \nabla_{\phi} L_V$$

本頁為常見 rollout surrogate 寫法；嚴格起點折扣目標需沿用前頁的時間權重。

TD error 與 Advantage：數值演算

用一步 reward 加上下一狀態價值，提供 Actor 與 Critic 的學習訊號。

$$y_t = r_{t+1} + \gamma(1 - d_t)V_{\phi_k}(s_{t+1}), \quad \delta_t = y_t - V_{\phi_k}(s_t)$$

$$r = 2, \gamma = 0.9, V(s) = 10, V(s') = 12, d = 0$$

$$y = 2 + 0.9 \times 12 = 12.8, \quad \delta = 12.8 - 10 = 2.8$$

當 Critic 等於真實策略價值時，條件期望下的 TD error 才是無偏 Advantage 估計。

A2C 、 A3C 與多步估計

Actor-Critic 不限於單步更新，可使用一段 rollout 的實際回報加上 bootstrap 。

$$y_t^{(n)} = \sum_{l=0}^{n-1} \gamma^l r_{t+l+1} + \gamma^n V_{\text{old}}(s_{t+n})$$

$$\hat{A}_t = y_t^{(n)} - V_{\text{old}}(s_t)$$

方法	資料與更新方式
A2C	同步彙整多個環境的 rollout 後更新
A3C	多個 worker 非同步更新共享參數

DDPG：確定性 Actor 與 Q Critic

Critic 學 replay 裡實際執行的動作，Actor 則用目前動作輸出尋找較高 Q 值。

$$a = \mu_{\theta}(s) + \epsilon, \quad y = r + \gamma(1 - d)Q_{\phi^{-}}(s', \mu_{\theta^{-}}(s'))$$

$$J_{\text{actor}} = \mathbb{E}_{s \sim \mathcal{D}}[Q_{\phi}(s, \mu_{\theta}(s))], \quad \nabla_{\theta} J_{\text{actor}} = \mathbb{E} \left[\nabla_a Q_{\phi}(s, a) \Big|_{a=\mu_{\theta}(s)} \nabla_{\theta} \mu_{\theta}(s) \right]$$

$$\theta^{-} \leftarrow \tau \theta + (1 - \tau) \theta^{-}, \quad \phi^{-} \leftarrow \tau \phi + (1 - \tau) \phi^{-}$$

TD3：降低錯誤 Q 值的影響

在 DDPG 基礎上，加入雙 Critic、延遲策略更新與目標策略平滑。

$$\tilde{a}' = \text{clip}(\mu_{\theta^-}(s') + \text{clip}(\epsilon, -c, c), a_{\min}, a_{\max})$$

$$y = r + \gamma(1 - d) \min_{i=1,2} Q_{\phi_i^-}(s', \tilde{a}')$$

取較小的 target Q 降低高估；Critic 多次更新後，Actor 才更新。

標準 TD3 有六個網路實例：一個 Actor、兩個 Critics，以及各自的 target。

SAC：最大熵目標

在高回報之外保留策略多樣性，並將熵納入 soft Bellman target 。

$$J = \mathbb{E} \left[\sum_t \gamma^t (r_{t+1} + \alpha_{\text{temp}} \mathcal{H}(\pi_{\theta}(\cdot \mid s_t))) \right]$$

$$a' \sim \pi_{\theta}(\cdot \mid s'), \quad y = r + \gamma(1 - d) \left[\min_i Q_{\phi_i^-}(s', a') - \alpha_{\text{temp}} \log \pi_{\theta}(a' \mid s') \right]$$

使用 off-policy 資料與隨機 Actor 。溫度可固定，或依目標熵自動調整。

Trust Region 與重要性比率

策略更新太大，舊資料上的局部改善估計可能失準。

$$\rho_t(\theta) = \frac{\pi_\theta(a_t \mid s_t)}{\pi_{\text{old}}(a_t \mid s_t)}, \quad L_{\text{sur}} = \mathbb{E}_{\text{old}}[\rho_t(\theta) \hat{A}_t]$$

$$\text{TRPO: } \max_{\theta} L_{\text{sur}} \quad \text{s.t.} \quad \mathbb{E}_{\text{old}}[D_{\text{KL}}(\pi_{\text{old}} \parallel \pi_\theta)] \leq \delta$$

動作機率比率不會完整校正新舊策略之間的所有狀態分布改變。

GAE：多步 TD residual 的加權

由短期 TD 到較長期回報，調整偏誤與變異之間的取捨。

$$\delta_t = r_{t+1} + \gamma(1 - d_t)V_{\text{old}}(s_{t+1}) - V_{\text{old}}(s_t)$$

$$\hat{A}_t^{\text{GAE}} = \sum_{l=0}^{K-1} (\gamma\lambda)^l \delta_{t+l}$$

$$\lambda = 0 : \hat{A}_t = \delta_t; \quad \lambda = 1 : \hat{A}_t = G_t - V_{\text{old}}(s_t) \text{ (complete episode)}$$

PPO-Clip：改善方向的飽和

取原始項與截斷項的較小值，移除過度改善的額外誘因。

$$L^{\text{CLIP}} = \mathbb{E}_{\text{old}} \left[\min \left(\rho_t \hat{A}_t, \text{clip}(\rho_t, 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right]$$

$$\hat{A}_t > 0 : \rho_t > 1 + \epsilon \Rightarrow \text{upper saturation}$$

$$\hat{A}_t < 0 : \rho_t < 1 - \epsilon \Rightarrow \text{lower saturation}$$

Clip 修改的是目標函數，不保證所有機率比率或 KL 都受硬性限制。

PPO clipping：正負 Advantage 的例子

設截斷幅度為兩成，比較原始項、截斷項與實際採用值。

$\hat{A}$	ρ	$\rho \hat{A}$	$\text{clip}(\rho) \hat{A}$	min
+2	1.4	2.8	2.4	2.4
+2	0.6	1.2	1.6	1.2
-2	0.6	-1.2	-1.6	-1.6
-2	1.4	-2.8	-2.4	-2.8

$$\epsilon = 0.2, \quad \rho_{\text{clip}} = \text{clip}(\rho, 0.8, 1.2)$$

PPO 的完整更新流程

順序	操作
收集	固定採樣策略，保存動作、reward、舊 log-probability 與 value
估計	計算 GAE 與 value target，同一批內保持固定
更新	用有限個 epochs 更新 clipped Actor loss 與 Critic loss
監測	觀察 KL、entropy、clip fraction 與獨立測試回報
重採樣	改用更新後的策略收集下一批資料

$$y_t = \hat{A}_t + V_{\text{old}}(s_t), \quad L_V = \mathbb{E}[(V_{\phi}(s_t) - \text{sg}(y_t))^2]$$

演算法比較

方法	資料策略	Actor	價值／ target
DQN	Off-policy	無獨立 Actor	Q ，下一步取最大
REINFORCE	On-policy	機率分布	完整 MC 回報，可加 baseline
A2C ／ A3C	On-policy	機率分布	通常 V ， n-step 或 GAE
DDPG ／ TD3	Off-policy	確定性動作	Q ， target actor 提供動作
SAC	Off-policy	機率分布	雙 Q ， target 包含熵
PPO	On-policy	機率分布	通常 V ， GAE 與 clip

課堂練習：計算與推理

把 Grid World 的一步成本改成兩分，兩種迭代的最優策略是否改變？

在 Policy Gradient 推導中，哪一步使用了環境與策略參數無直接關係的假設？

為何可以刪去過去 reward，卻不能任意刪去未來 reward？

Critic 誤差很小、測試回報卻很低，可能出現什麼情況？

本週重點與延伸閱讀

價值估計提供未來回報的預測；策略梯度把回報差異轉成動作機率的更新。

$$\nabla_{\theta} J = \mathbb{E} \left[\sum_t \gamma^t \nabla_{\theta} \log \pi_{\theta}(a_t | s_t) (G_t - b(s_t)) \right]$$

Grid World：分清楚「固定策略評估」與「對動作取最大值」。

Actor-Critic：分清楚 value target、Advantage 與 Actor loss。

延伸閱讀：PPO、GAE、TD3、Soft Actor-Critic Algorithms and Applications。